머신 러닝
(Machine Learning)

데이터 분석에서 가장 중요한 것은?

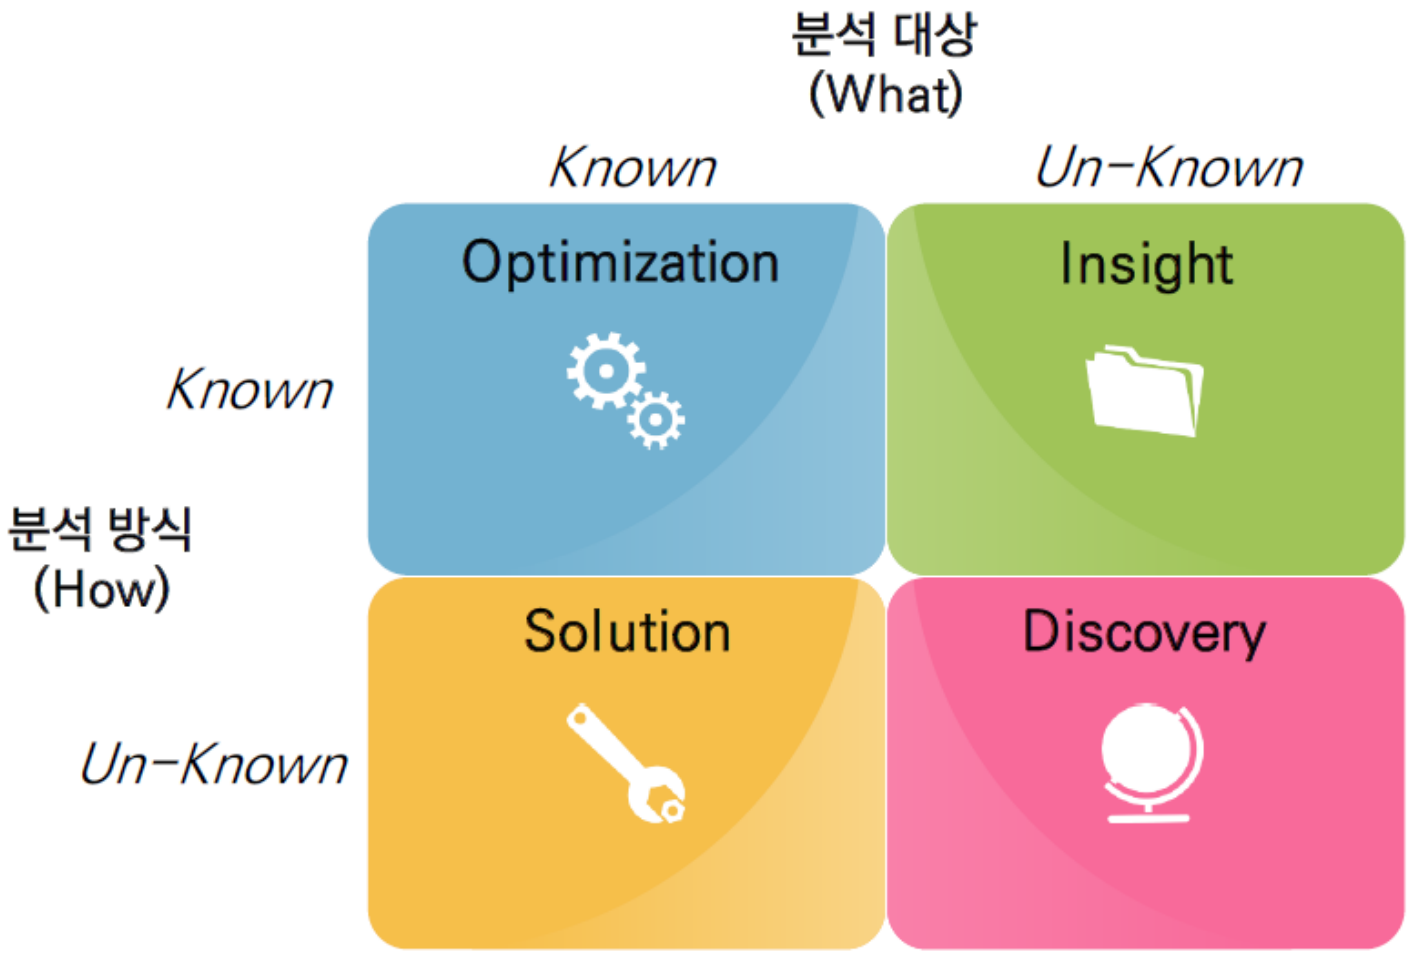

Insight vs. Optimazation

Insight

탐색적 자료 분석(Exploratory Data Analysis)

데이터의 특징과 내재하는 구조적인 관계를 알아내기 위한 분석 기법으로 이러한 자료의 탐색 과정을 통하여 얻은 정보를 기초로 통계모형을 세울 수 있음
미지의 특성을 파악하고 자료구조를 파악할 수 있는 증거 수집의 과정
Looking at data to see what it seems to say. It's concentrates on simple arithmetic and easy-to-draw picture. *John Tukey, 1977*

Optimization

기계학습(Machine Learning)

어떻게 하면 더 빨리 학습시키고 어떻게 하면 더 정확히 예측할 수 있을까에 대한 연구를 하며 데이터 전처리, 파생 변수 추가, 모형 선택 등의 방법을 통해서 예측 모형의 평가 점수를 높이는 과정
A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at tasks in T, as measured by P, improves with experience E. *Tom. Mitchell, 1997*

분석을 잘 하려면?

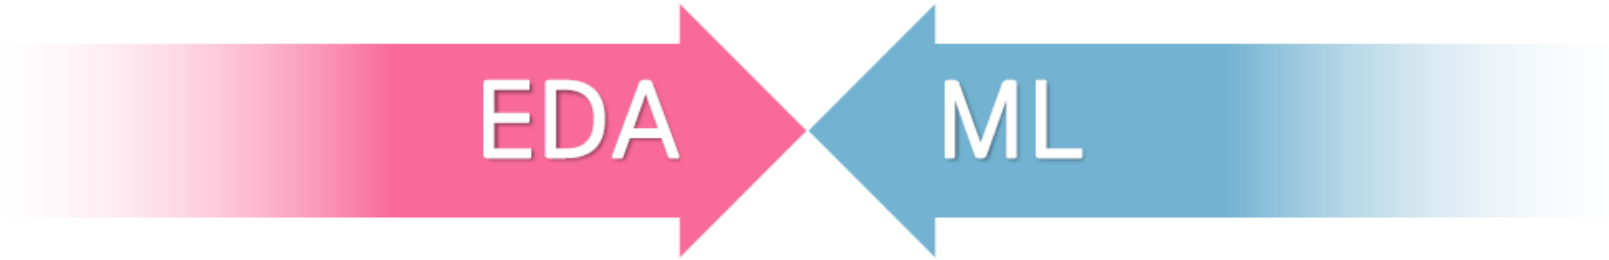

데이터 탐색 및 시각화

의미 있는 정보는 무엇이 있을까?

- 데이터를 잘 다룰 수 있어야 함
- 데이터의 부분집합 추출 및 병합 등의 작업이 주를 이룸
- 데이터 시각화를 통해 탐색 결과를 이해하기 쉽도록 함

파이썬의 패키지

❖Numpy & Pandas : 데이터를 다루기 위한 패키지

❖Matplotlib & Seaborn : 데이터를 시각화 하기 위한 패키지

예측력이 높은 모형 생성

어떻게 하면 모형이 예측을 잘 할 수 있을까?

- 데이터 전처리, 파생변수 추가
- 머신러닝 모형 생성 및 예측
- 모형 평가

파이썬의 패키지

❖Scikit-learn : 기계학습 라이브러리

❖Statsmodels : 통계 라이브러리

파이썬 언어를 이용한 데이터 분석 패키지

- 머신러닝 패키지
  - Scikit-Learn : 데이터 마이닝 기반의 머신러닝.
- 행렬 / 선형대수 / 통계 패키지
  - NumPy : 행렬과 선형대수를 다루는 패키지.
  - SciPy : 자연과학과 통계를 위한 패키지.
- 데이터 핸들링
  - Pandas : 데이터 처리 패키지, 2차원 데이터 처리에 특화.
- 시각화
  - Matplotlib : 파이썬의 대표적인 시각화 패키지.
  - Seaborn : matplotlib 기반으로 만들었지만, 판다스와의 쉬운 연동, 더 함축적인 API, 분석을 위한 다양한 유형의 그래프/차트 제공.
- 서드파티 라이브러리
- 아이파이썬(IPython, Interactive Python) 툴인 주피터 노트북(Jupyter Notebook)

넘파이(NumPy, Numerical Python)

- 파이썬에서 선형대수 기반의 프로그램을 쉽게 만들 수 있도록 지원하는 대표적인 패키지.
- 대량 데이터의 배열 연산을 가능하게 하므로 빠른 배열 연산 속도를 보장.
- C/C++과 같은 저수준 언어 기반의 호환 API를 제공.
- 파이썬 언어 자체가 가지는 수행 성능의 제약이 있으므로 수행 성능이 매우 중요한 부분은 C/C++ 기반의 코드로 작성하고, 이를 넘파이에서 호출하는 방식으로 쉽게 통합 가능.
- 다양한 데이터 핸들링 기능도 제공.
- 넘파이 모듈의 임포트 방법
  - import numpy as np
  - 넘파이 기반 데이터 타입 : ndarray
- 넘파이 array() 함수는 파이썬의 리스트와 같은 다양한 인자를 입력 받아서 ndarray로 변환하는 기능을 수행.

넘파이 ndarray 배열의 차원들

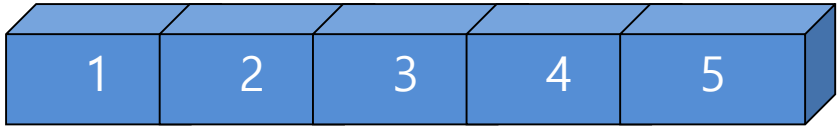

1차원 배열

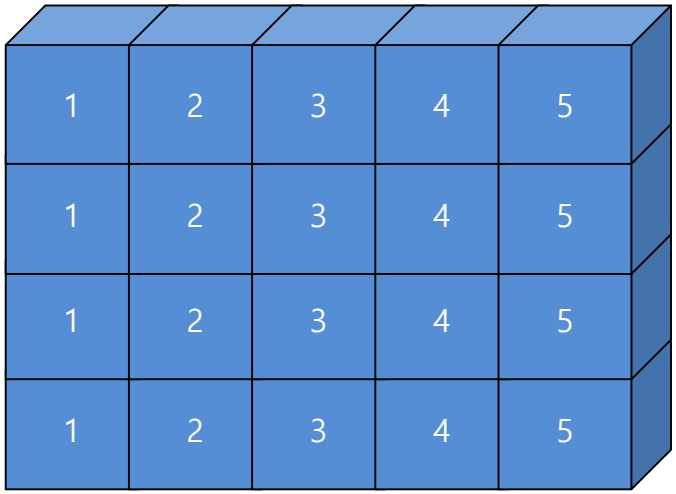

2차원 배열

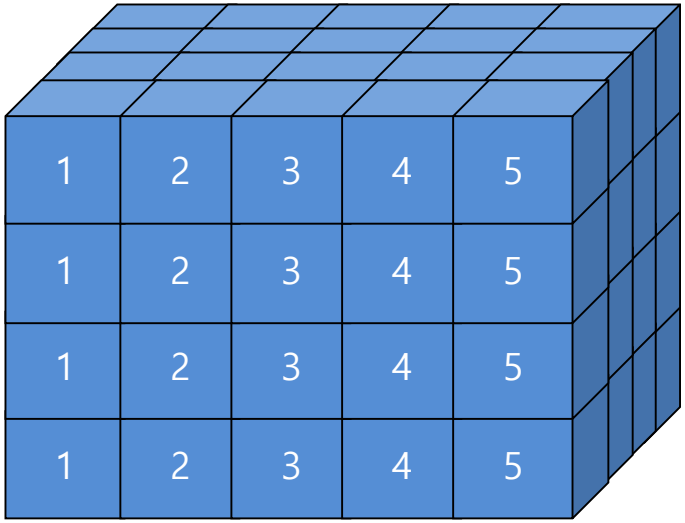

3차원 배열

ndarray 배열의 shape 변수

- ndarray의 크기, 즉 행과 열의 수를 튜플 형태로 제공, 차원 확인까지 가능.

```
array1 = np.array([1,2,3])
print('array1 type:', type(array1))
print('array1 array 형태:', array1.shape)

array2 = np.array([[1,2,3], [2,3,4]])
print('array2 type:', type(array2))
print('array2 array 형태:', array2.shape)

array3 = np.array([[1,2,3]])
print('array3 type:', type(array3))
print('array3 array 형태:', array3.shape)
```

ndarray 배열

- 차원 확인 : ndarray.ndim

```
print('array1: {:0}차원, array2: {:1}차원, array3: {:2}차원'
                                        .format(array1.ndim,array2.ndim,array3.ndim))
```

- 데이터 타입 확인 : ndarray.dtype

```
list1 = [1,2,3]
print(type(list1))

array1 = np.array(list1)
print(type(array1))
print(array1, array1.dtype)
```

ndarray 배열

- 서로 다른 데이터 타입의 ndarray에서의 처리

```
list2 = [1, 2, 'test']
array2 = np.array(list2)
print(array2, array2.dtype)

list3 = [1, 2, 3.0]
array3 = np.array(list3)
print(array3, array3.dtype)
```

- ndarray 내 데이터 값의 타입 변경 : astype()

```
array_int = np.array([1, 2, 3])
array_float = array_int.astype('float64')
print(array_float, array_float.dtype)

array_int1= array_float.astype('int32')
print(array_int1, array_int1.dtype)

array_float1 = np.array([1.1, 2.1, 3.1])
array_int2= array_float1.astype('int32')
print(array_int2, array_int2.dtype)
```

3차원 배열의 축(axis)

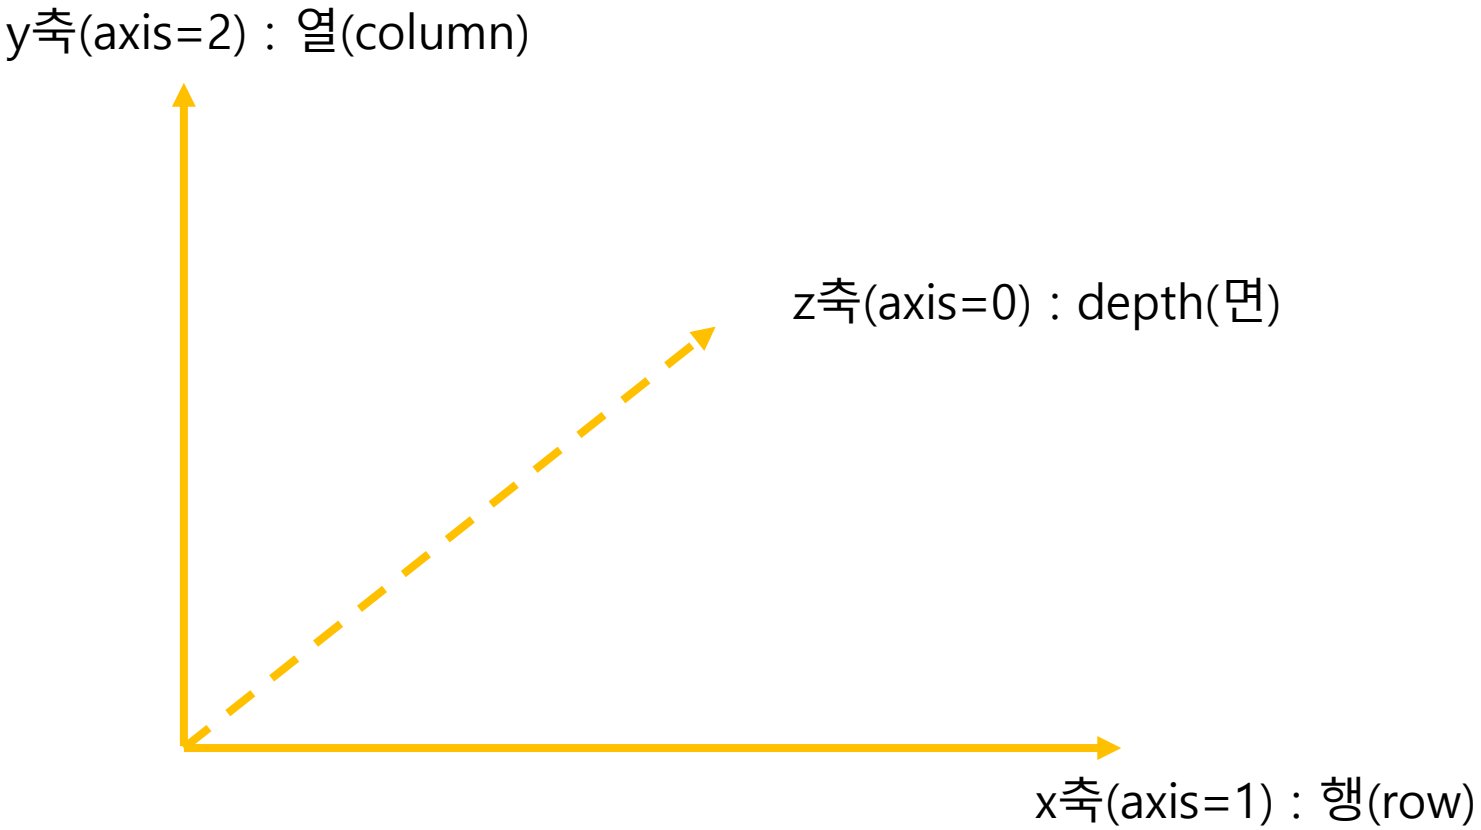

3차원 배열에서 axis(축)의 의미

axis 이해

➢ numpy의 sum 함수 사용 예

- 다음 코드는 3차원 배열을 만들고, 3차원 배열의 합을 구하는 코드

```
>>> arr = np.arange(0, 2*3*4)
>>> len(arr)
    24
>>> arr
    array([ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23])
>>> v = arr.reshape([2,3,4]) # 차원 변환 [2, 3, 4]; depth: 2, row: 3, column: 4
>>> v
    array([[[ 0, 1, 2, 3],
            [ 4, 5, 6, 7],
            [ 8, 9, 10, 11]],

           [[12, 13, 14, 15],
            [16, 17, 18, 19],
            [20, 21, 22, 23]]])
```

3차원 배열의 축(axis) - 실습 데이터

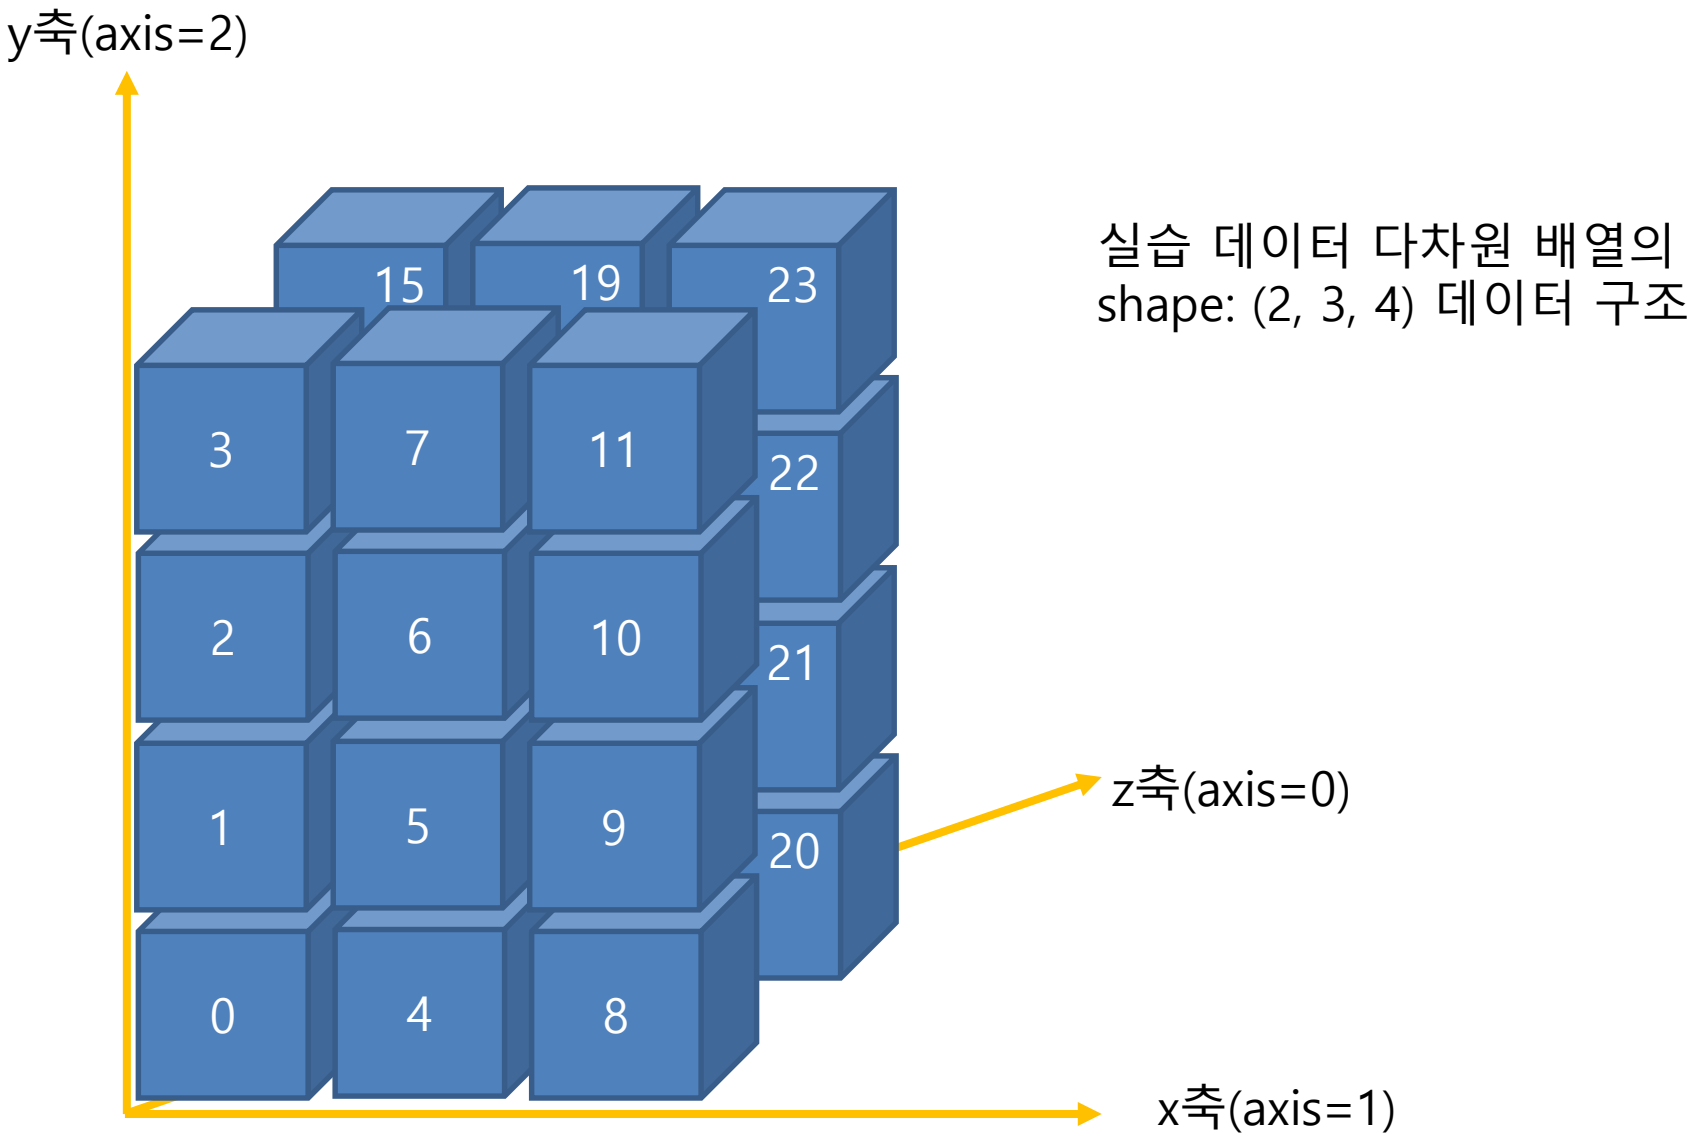

실습 데이터 다차원 배열의
shape: (2, 3, 4) 데이터 구조

axis 이해

```
>>> v.shape # v의 형상
(2, 3, 4)
>>> v.ndim # v의 차원
3
>>> v.sum() # axis=None 기준 합계
276
```

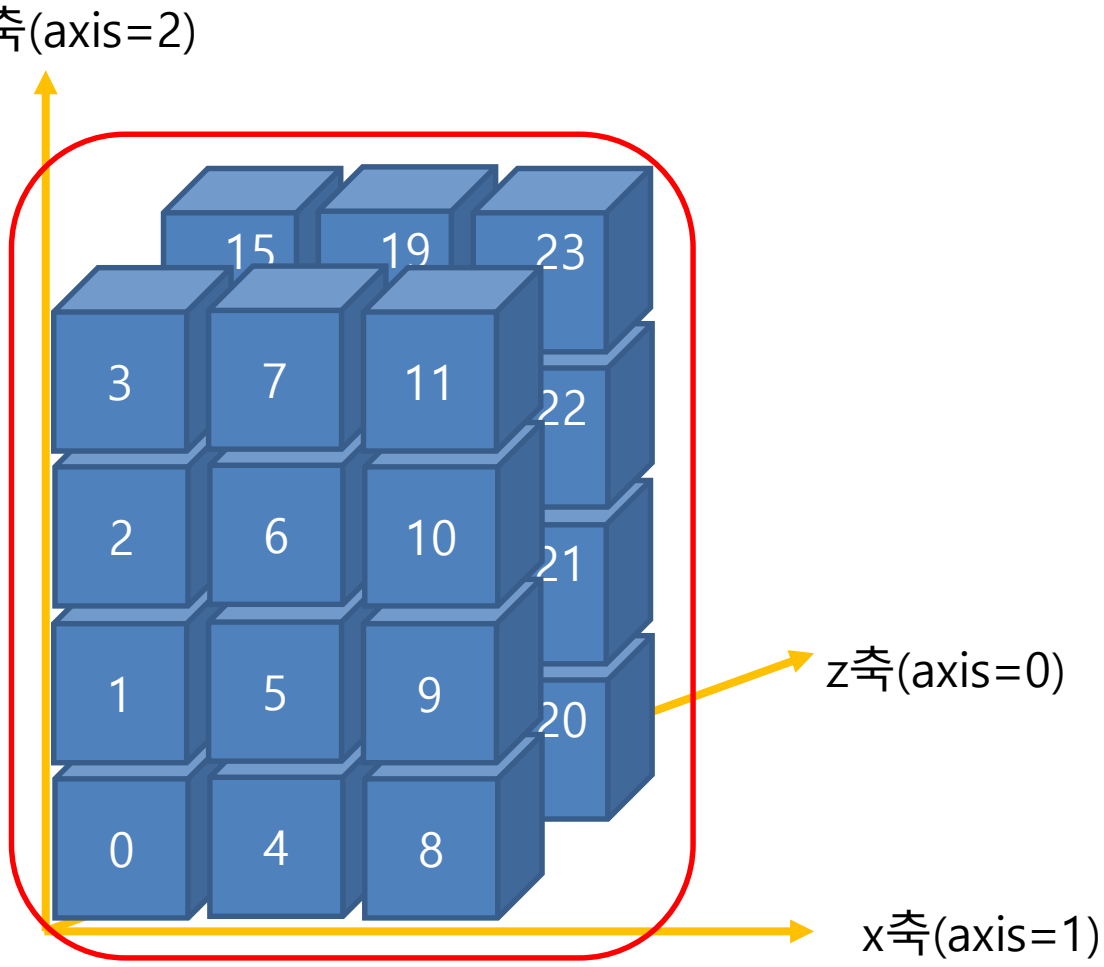

axis 이해

```
>>> res01=v.sum(axis=0) # axis=0 기준 합계
>>> res01.shape
(3, 4)
>>> res01
array([[12, 14, 16, 18],
       [20, 22, 24, 26],
       [28, 30, 32, 34]])
```

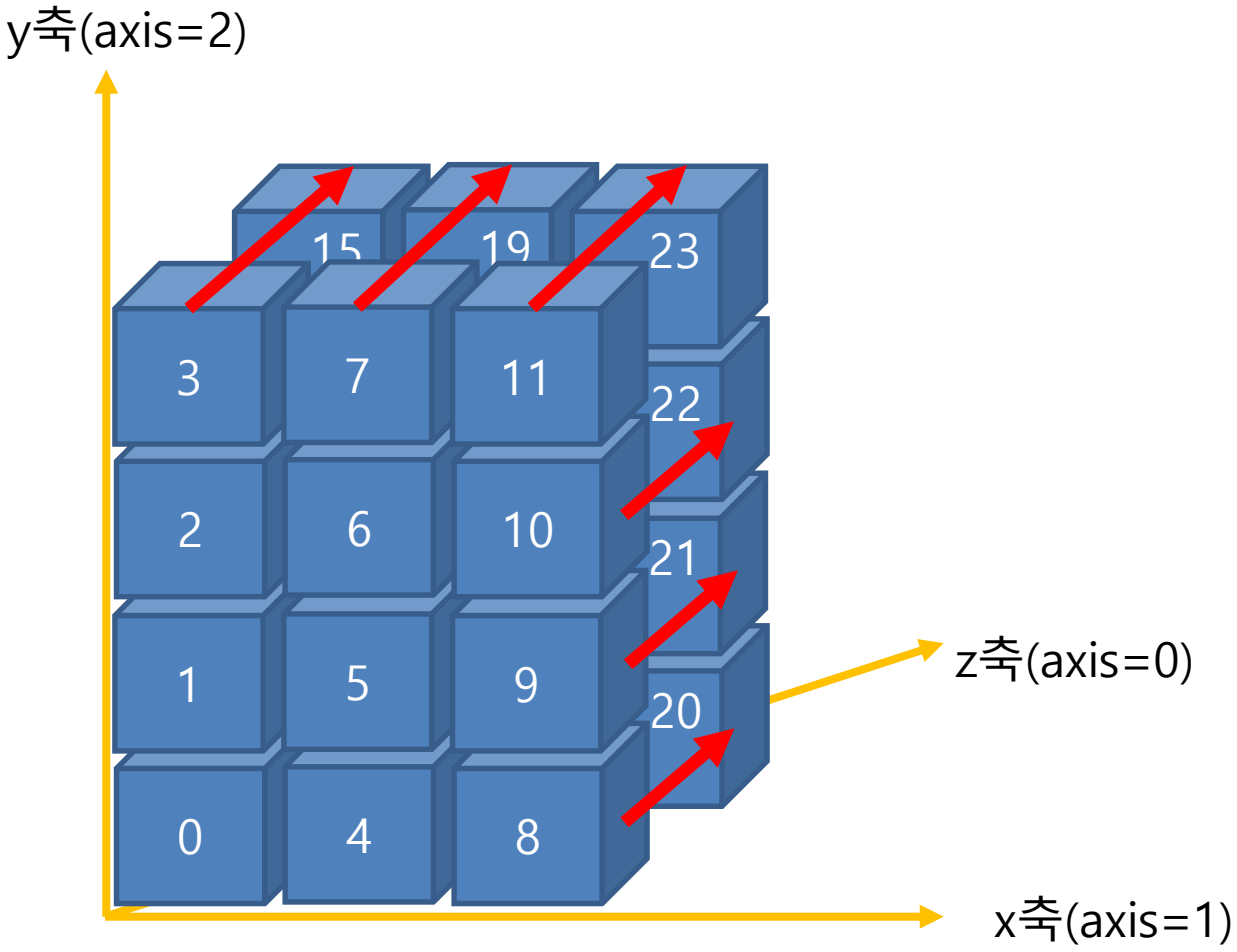

axis 이해

```
>>> res02=v.sum(axis=1) # axis=1 기준 합계
>>> res02.shape
(2, 4)
>>> res02
array([[ 12, 15, 18, 21],
       [48, 51, 54, 57]])
```

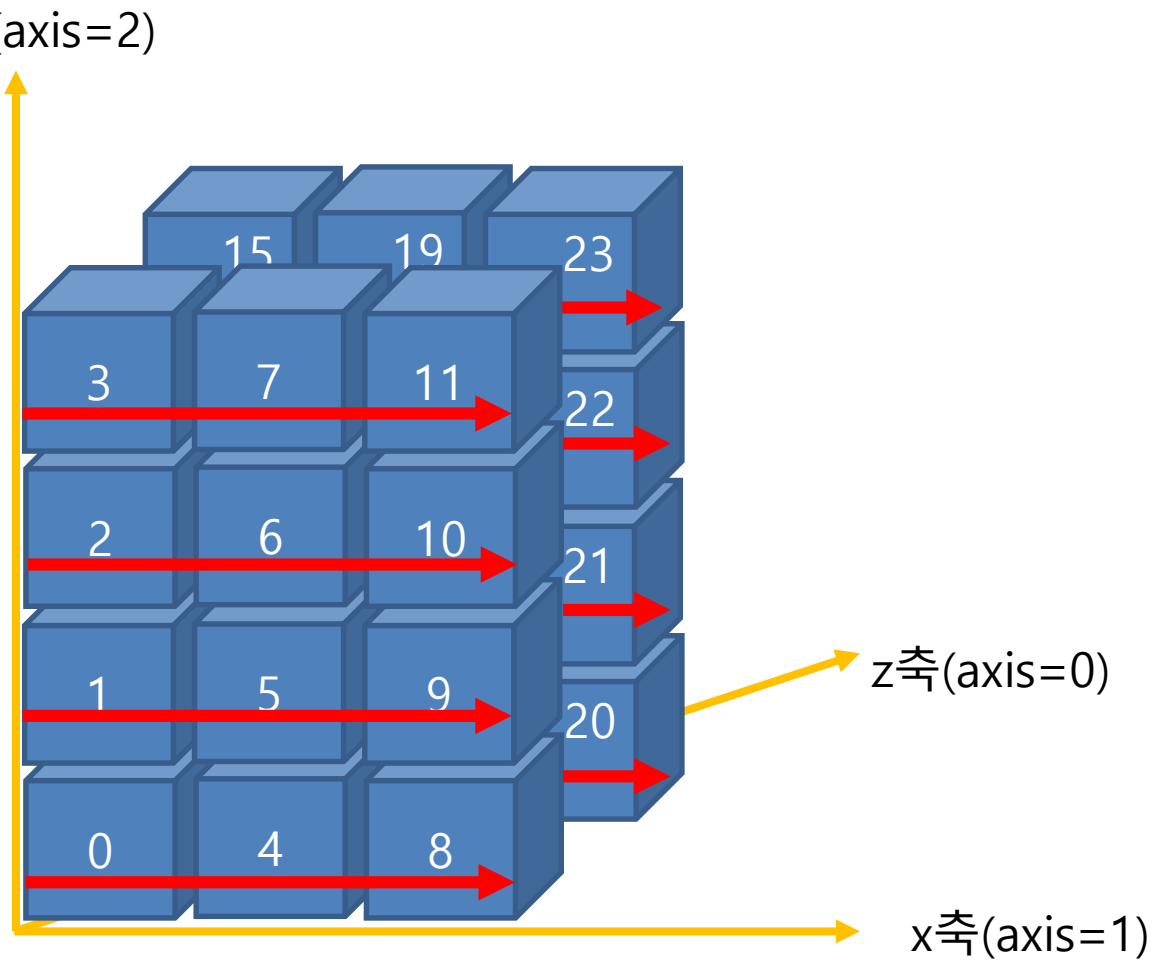

axis 이해

```
>>> res03=v.sum(axis=2) # axis=2 기준 합계
>>> res03.shape
(2, 3)
>>> res03
array([[ 6, 22, 38],
       [54, 70, 86]])
```

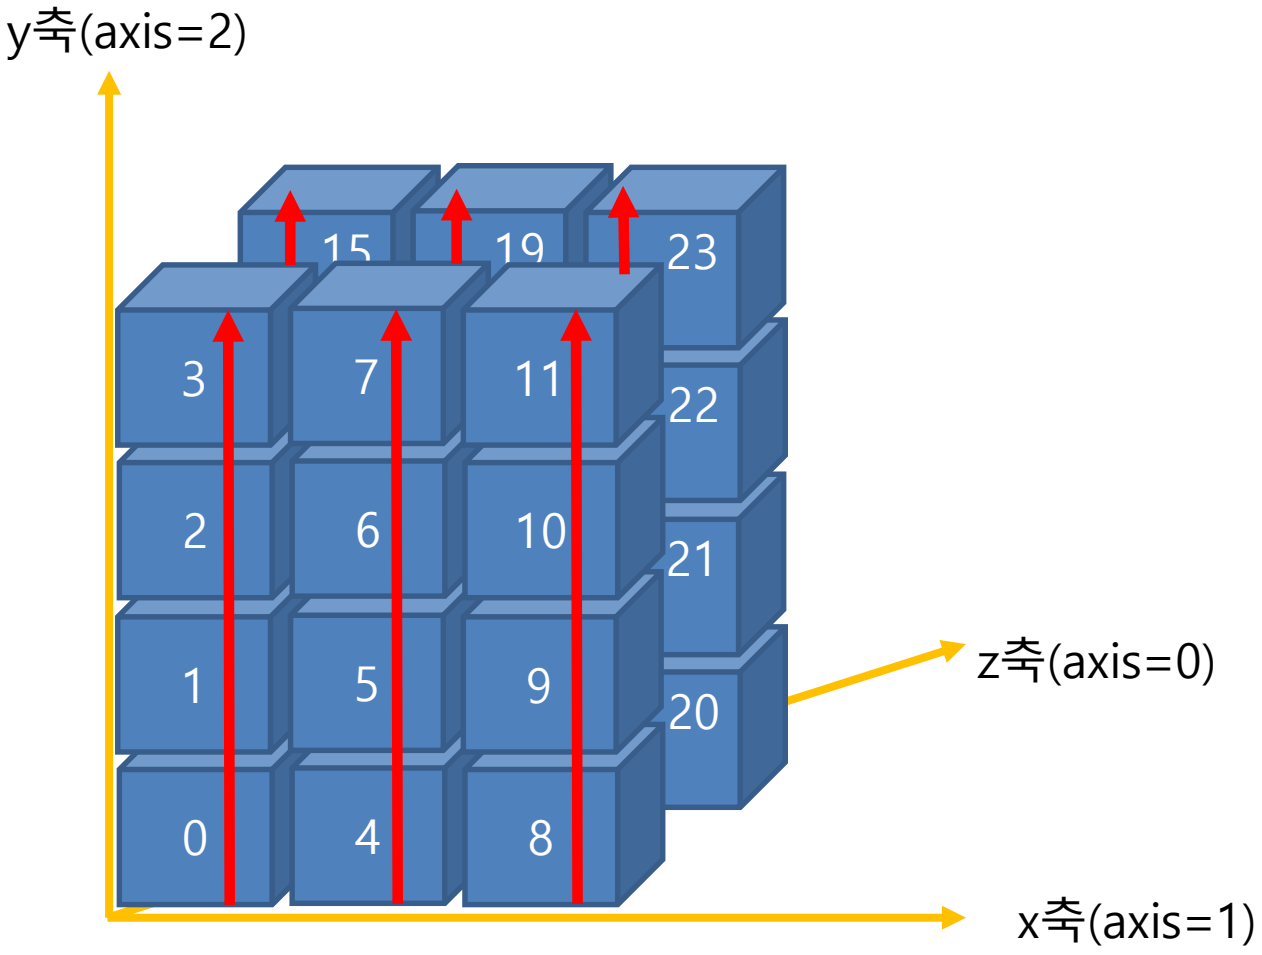

머신러닝의 개념

인공지능 > 머신러닝 > 딥러닝

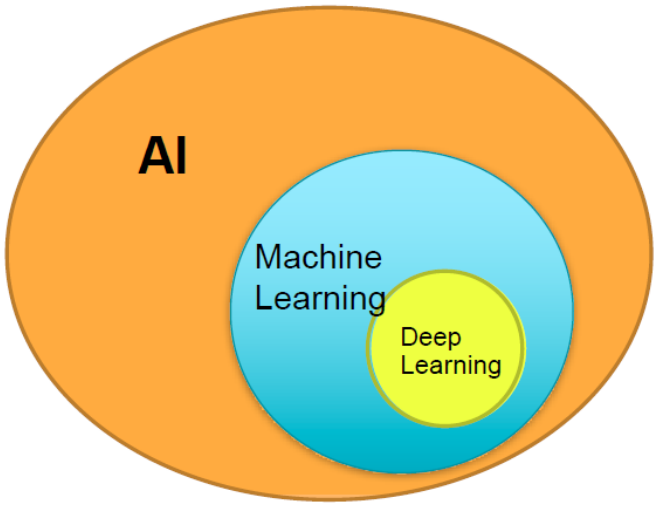

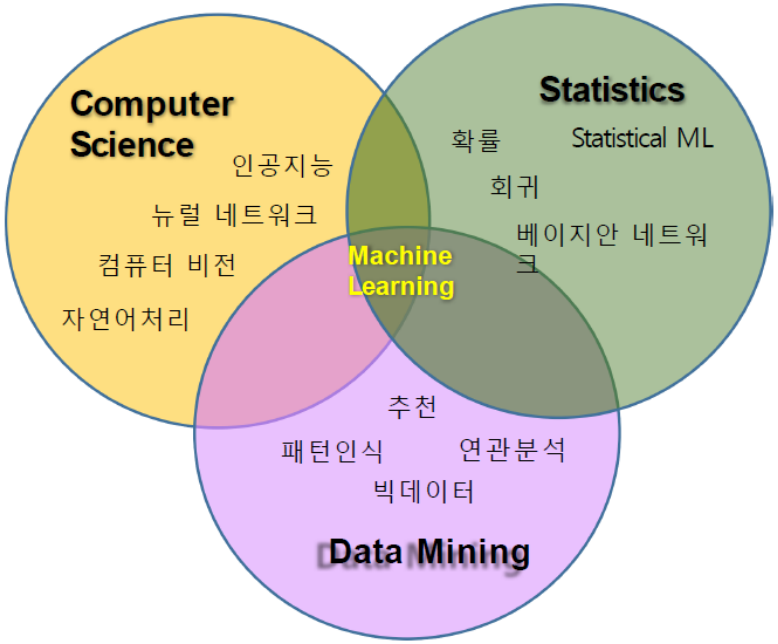

머신러닝의 개념

- 어플리케이션을 수정하지 않고도, 데이터를 기반으로 패턴을 학습하고 결과를 예측하는 알고리즘 기법을 통칭.
- 데이터를 기반으로 통계적인 신뢰도를 강화하고, 예측 오류를 최소화하기 위한 다양한 수학적 기법을 적용해 데이터 내의 패턴을 스스로 인지하고, 신뢰도 있는 예측 결과를 도출.
- 데이터 분석 영역은 재빠르게 머신러닝 기반의 예측분석(Predictive Analysis)으로 재편되고 있음.
- 많은 데이터 분석가와 데이터 과학자가 머신러닝 알고리즘 기반의 새로운 예측 모델을 이용해 더욱 정확한 예측 및 의사 결정을 도출하고 있으며, 데이터에 감춰진 새로운 의미와 통찰력(insight)를 발굴해 놀랄 만한 이익으로 연결시키고 있음.
- 귀납적 학습 : 데이터만 주어지더라도 구조를 추론하려고 시도하기 때문.

머신러닝의 분류

- 지도학습(Supervised Learning)
  - 회귀(Regression) : 단순 선형 회귀 / 다항 회귀
  - 분류(Classification) : 이진 분류(로지스틱 회귀) / 다중 분류
  - 추천 시스템
  - 시각/음성 감지/인지
  - 텍스트 분석, NLP

- 비지도학습(Un-supervised Learning)
  - 군집(cluster) 분석 : ex) k 평균 알고리즘
  - 연관(association) 분석
  - 차원 축소 : ex) 주성분 분석

머신러닝 모델 개선

- 최적의 머신러닝 알고리즘과 모델 파라메터를 구축하는 능력도 중요하지만,
- 데이터를 이해하고 효율적으로 가공, 처리, 추출해서 최적의 데이터를 기반으로 알고리즘을 구동할 수 있도록 준비하는 능력이 무엇보다 더 중요.
- 다양하고 광대한 데이터를 기반으로 만들어진 머신러닝 모델은 더 좋은 품질을 약속.
- 앞으로 많은 회사의 경쟁력은 어떠한 품질의 데이터로 만든 머신러닝 모델이냐에 따라 결정.

파이썬이 R에 비해 뛰어난 점

- 쉽고 뛰어난 개발 생산성으로 전 세계 개발자들이 선호. 특히 구글, 페이스북 등 유수의 IT 업계에서도 파이썬의 높은 생산성으로 인해 활용도가 매우 높음.
- 오픈 소스 계열의 전폭적인 지원을 받고 있으며 놀라울 정도의 많은 라이브러리로 인해 개발 시 높은 생산성을 보장.
- 인터프리터 언어(Interpreter Language)의 특성상 속도는 느리지만, 대신에 뛰어난 확장성, 유연성, 호환성으로 인해 서버, 네트워크, 시스템, IOT, 심지어 데스크톱까지 다양한 영역에서 사용되고 있음.
- 머신러닝 어플리케이션과 결합한 다양한 어플리케이션 개발이 가능.
- 엔터프라이즈 아키텍처로의 확장 및 마이크로 서비스 기반의 실시간 연계 등 다양한 기업 환경으로의 확산이 가능.
- 딥러닝 프레임워크인 텐서플로(TensorFlow), 케라스(Keras), 파이토치(PyTorch) 등에서 우선 정책으로 파이썬을 지원.

머신러닝 모델의 성능 평가 - 혼동행렬(Confusion Matrix)

- 혼동행렬이란 특정 분류 모델의 성능을 평가하는 지표로, 실제값과 모델이 예측한 예측값을 한 눈에 알아볼 수 있게 배열한 행렬.

		예측 클래스 N	예측 클래스 Y
실제 클래스	N	True/Negative 실제 N. 예측 Y	False/Positive 실제 N, 예측 Y
	Y	False/Negative 실제 Y. 예측 Y	True/Positive 실제 Y, 예측 Y

- 혼동행렬의 구성 요소
  - True Negative(TN): 실제 값도 거짓이고 모델의 예측 값도 거짓인 경우.
  - False Positive (FP): 실제 값은 거짓이나 모델의 예측 값이 참인 경우.
  - False Negative(FN): 실제 값은 참이나 모델의 예측 값이 거짓인 경우.
  - True Positive(TP): 실제 값이 참이고 모델의 예측 값도 참인 경우.

머신러닝 모델의 성능 평가 - 혼동행렬 예

		Predicted Target	
		N(일반 고객)	Y(보험 사기자)
Actual Target	일반 고객 (Negative)	1613 True/Negative 실제 N. 예측 N	22 False/Positive 실제 N, 예측 Y
	보험 사기자 (Positive)	81 False/Negative 실제 Y. 예측 N	77 True/Positive 실제 Y, 예측 Y

- 실제 일반 고객을 일반 고객(Negative)으로 바르게 분류(True)한 고객의 수가 1613명
- 실제 일반 고객을 보험 사기자(Positive)로 틀리게 분류(False)한 고객의 수가22명
- 실제 보험 사기자를 일반 고객(Negative)으로 틀리게 분류(False)한 고객의 수가 81명
- 실제 보험 사기자를 보험 사기자(Positive)로 바르게 분류(True)한 고객의 수가 77명

머신러닝 모델의 성능 평가 - 분류 모델 평가 지표

- **혼동행렬에 기반한 분류 모델 평가 지표**

1.**정확도(Accuracy):** 모델이 전체 중에서 예측을 올바르게 한 비율

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

2. **재현율(Recall)**: 실제 참인 값 중 모델이 참으로 예측한 값의 비율. 재현율이 낮을 경우 암인 사람에게 암이 아니라고 하였으니 심각한 결과를 초래할 것.

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

3. **정밀도(Precision)**: 모델이 참으로 예측한 값 중 실제 참인 값의 비율. 정밀도가 낮을 경우 암이 아닌 사람에게 암이라고 했으니 불필요한 치료가 발생할 수 있음.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

4. **F1 점수(F1-Score)**: 정밀도와 재현율의 조화 평균

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

sklearn의 train_test_split() 사용법

➢ 개요

머신러닝 모델을 학습하고 그 결과를 검증하기 위해서는 원래의 데이터를 Training, Validation, Testing의 용도로 나누어 다뤄야 한다. 그렇지 않고 Training에 사용한 데이터를 검증용으로 사용하면 시험문제를 알고 있는 상태에서 공부를 하고 그 지식을 바탕으로 시험을 치루는 꼴이므로 제대로 된 검증이 이루어지지 않기 때문이다.

딥러닝을 제외하고도 다양한 기계학습과 데이터 분석 툴을 제공하는 scikit-learn 패키지 중 model_selection에는 데이터 분할을 위한 train_test_split 함수가 들어있다.

sklearn의 train_test_split() 사용법

➢ Parameter & Return

```
from sklearn.model_selection import train_test_split
train_test_split(arrays, test_size, train_size, random_state, shuffle, stratify)
```

(1) Parameter

- **arrays** : 분할시킬 데이터를 입력 *(Python list, Numpy array, Pandas dataframe 등..)*
- **test_size** : 테스트 데이터셋의 비율(float)이나 갯수(int) *(default = 0.25)*
- **train_size** : 학습 데이터셋의 비율(float)이나 갯수(int) *(default = test_size의 나머지)*
- **random_state** : 데이터 분할시 셔플이 이루어지는데 이를 위한 시드값 *(int나 RandomState로 입력)*
- **shuffle** : 셔플 여부 설정 *(default = True)*
- **stratify** : 지정한 Data의 비율을 유지한다. 예를 들어, Label Set인 Y가 25%의 0과 75%의 1로 이루어진 Binary Set일 때, stratify=Y로 설정하면 나누어진 데이터셋들도 0과 1을 각각 25%, 75%로 유지한 채 분할된다.

(2) Return

- **X_train, X_test, Y_train, Y_test** : arrays에 데이터와 레이블을 둘 다 넣었을 경우의 반환이며, 데이터와 레이블의 순서쌍은 유지된다.
- **X_train, X_test** : arrays에 레이블 없이 데이터만 넣었을 경우의 반환

sklearn의 train_test_split() 사용법

- **Example**

```
import numpy as np from sklearn.model_selection import train_test_split


X = [[0,1],[2,3],[4,5],[6,7],[8,9]]
Y = [0,1,2,3,4]


# 데이터(X)만 넣었을 경우
X_train, X_test = train_test_split(X, test_size=0.2, random_state=123)
# X_train : [[0,1],[6,7],[8,9],[2,3]]
# X_test : [[4,5]]


# 데이터(X)와 레이블(Y)을 넣었을 경우
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.33, random_state=321)
# X_train : [[4,5],[0,1],[6,7]]
# Y_train : [2,0,3]
# X_test : [[2,3],[8,9]]
# Y_test : [1,4]
```